

SORBONNE UNIVERSITÉ

RAPPORT DE ARF

TME 1 - 6

SAMU TAMMINEN

Table des matières

1	TME 1 : Arbres de décision, sélection de modèles	2
1.1	Q1.3 Interpretation de l'entropie	2
1.2	Q1.4 - 6 La profondeur d'arbre	2
1.3	Q1.7 - Sur et sous apprentissage	2
2	TME 2 : Estimation de densité	3
2.1	Méthode des histogrammes	3
2.2	Méthode à noyaux	3
2.2.1	Comment choisir de manière automatique le meilleur taille de lissage h ? . . .	4
3	TME 3 : Descente de gradient	5
4	TME 4 et 5 : Perceptron	5
5	TME 5 : Support Vector Machine	5
5.1	Pistes de recherche	5

1 TME 1 : Arbres de décision, sélection de modèles

1.1 Q1.3 Interpretation de l'entropie

Calculer également la différence entre l'entropie et l'entropie conditionnelle pour chaque attribut. A quoi correspond une valeur de 0 ? une valeur de 1 ? Quel est le meilleur attribut pour la première partition ?

Quand la différence entre l'entropie et l'entropie conditionnelle est 0 quand la partition n'est pas du tout bon et un, quand la partition est le meilleur possible.

1.2 Q1.4 - 6 La profondeur d'arbre


En augmentant la profondeur maximale d'arbre, on obtient meilleur score. Mais ces scores ne sont pas un indicateur fiable, si nous ne faisons pas différence entre les données training et test.

1.3 Q1.7 - Sur et sous apprentissage

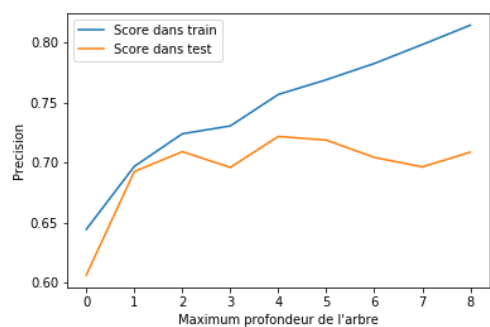
Le partition 0.8 / 0.2 dans Figure 1 (c) semble d'être le plus robuste pour test et training. La différence entre le score dans apprentissage et test est le plus petit parmi (a), (b) et (c).

Quand il y a que peu d'exemples d'apprentissage, l'erreur est plus élevée dans le test. Par contre quand on a beaucoup des d'exemples d'apprentissage, l'erreur dans le test est moins élevée.


FIGURE 1 – Score d'arbre de decision en faisant varier le profondeur




(a) Donnée apprentissage et test : 0.2 / 0.8



(b) Donnée apprentissage et test : 0.5 / 0.5



(c) Donnée apprentissage et test : 0.8 / 0.2



(d) Validation croisee

Avec validation croisée on obtient un score plus fiable et stable. Dans la figure Figure 1 (d) nous pouvons constater, comment le score augmente au début avec la profondeur maximale, mais à la fin il tombe. Ça c'est à cause de sous et sur apprentissage. Au début, on généralise beaucoup avec un arbre peu profond (sous apprentissage). Quand la profondeur se monte sur cinq, nous commençons à apprendre les données d'apprentissage à la façon trop détaillée et le score sur le test se tombe (sur apprentissage). La profondeur maximale 4 semble optimal.


2 TME 2 : Estimation de densité

Nous sommes intéressés de densité des services différents de Paris.


2.1 Méthode des histogrammes

La méthode la plus simple, méthode des histogrammes, il s'agit de partager la valeur continue (latitude et longitude) à les intervalles fixés et compter, combien d'occurrences chacun contient.


FIGURE 2 – Densité par méthode des histogrammes




(a) Les ATMs à Paris



(b) Histogramme avec 5 intervalles



(c) Histogramme avec 10 intervalles



(d) Histogramme avec 15 intervalles


On peut voir bien avec chaque discretization de Figure 2, que la densité maximum des ATMs est dans 9ième arrondissement. Par contre, la densité n'est pas très visible dans les endroits où la densité est moins forte (par exemple 13ième arrondissement). Surtout avec 15 étapes, nous ne voyons pas très bien.

2.2 Méthode à noyaux

Comme la méthode de histogramme ne permet pas de visualiser les atms bien avec 15 étapes, je vais fixer le variable étapes à 15 pour l'estimation par noyau. L'estimation par noyau a une variable


h qui est taille de lissage. On va varier d'abord h .

FIGURE 3 – Parzen comme fonction de Noyau



Dans Figure 3, si $h \geq 0.25$, l'estimation est "oversmoothed". $h = 0.15$ l'air le plus optimal, car il prend en compte les points partout à Paris, mais la densité est également visible.

FIGURE 4 – Gauss comme fonction de Noyau



Avec le gaussien (Figure 4), le meilleur paramètre de lissage est peut-être 0.05.

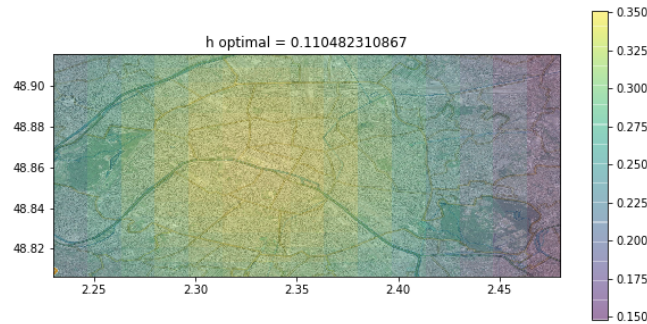
2.2.1 Comment choisir de manière automatique le meilleur taille de lissage h ?

Selon [A rule-of-thumb bandwidth estimator, 2018], nous pouvons estimer l'optimal taille de lissage h pour noyau de Gauss. L'estimation est définie dans Équation 1.

$$h = \left(\frac{4\hat{\sigma}^5}{3n} \right)^{\frac{1}{5}} \approx 1.06\hat{\sigma}n^{-1/5} \quad (1)$$

Nous obtenons $h=0.110482310867$ pour les données des ATMs à Paris, visualisé dans Figure 5.

FIGURE 5 – Densité avec la méthode de noyaux (Gauss) et lissage optimale



L'optimal "rule-of-thumb" estimateur minimise l'erreur de moindre carrée intégré (Mean integrated squared error). Il permet de montrer le "vraie" distribution, que les POIs vont suivre. J'ai visualisé également les autres POIs avec le noyaux de Gauss et l'optimal h . J'ai constaté que les visualisations ne sont pas très différentes. Les différentes POIs sont distribués à Paris plus ou moins à la même façon : en centre-ville la densité est grande, d'ailleurs moins. Donc je pense que ça sera difficile de classifier les POIs seulement par rapport ses localisations.

3 TME 3 : Descente de gradient

4 TME 4 et 5 : Perceptron

5 TME 5 : Support Vector Machine

5.1 Pistes de recherche

Références

A rule-of-thumb bandwidth estimator. Kernel density estimation — Wikipedia, the free encyclopedia, 2018. URL https://en.wikipedia.org/wiki/Kernel_density_estimation#A_rule-of-thumb_bandwidth_estimator. [Enligne; consulté 20 Mars 2018].